

李志轩

shawn.zx.lee@gmail.com | TEL: (+86)13609283080 | github.com/tweakzx | tweakzx.github.io

教育经历

中国科学院 计算技术研究所

2021/09 – 2024/07

硕士, 计算机软件与理论, GPA: 3.51

北京

- 推荐免试入学, 研究兴趣是基于 Kubernetes 的深度学习 GPU 集群, GPU 虚拟化与调度

西安交通大学

2017/08 – 2021/07

学士, 软件工程, GPA: 3.75, 排名: 10/108

西安, 陕西

- 推荐免试攻读硕士, 西安交通大学优秀毕业生, 校二等奖学金×2, 三等奖学金×1, 优秀学生×3

工作经历

华为

2024/07 – 至今

容器与 Serverless 域, 基础设施产品线, 云计算工程师

上海

- 异构资源管理 device plugins**: 面对 CCE 集群中昇腾、NVIDIA 等异构算力管理的挑战, 主导 Device Plugin 组件的维护与开发。设计并实现 NPU 网络信息采集、CCZ 可信计算域、灵衢参数面网络穿刺、健康探针等核心功能, 打通异构资源从注册到调度的完整链路, 保障生产集群 AI 工作负载稳定运行。
- NPU 虚拟化管理组件 vnpu-parted**: 针对 NPU 资源利用率低、切分配置复杂的问题, 开发 vNPU 虚拟化组件。支持 Ascend 310P3 和 910B3 等 NPU 设备的灵活切分, 设计后端核心逻辑与前端交互界面, 通过简化配置将异构算力使用门槛降低, 显著提升资源利用率。
- 推理负载管理 kthena**: 为解决 LLM 推理负载在 Kubernetes 上的编排难题, 推动 kthena 与 Volcano 插件集成。设计基于优先级的智能缩容策略, 完成 CCE 证书管理、EntryPod IP 下发等生产适配, 实现推理负载统一编排与自动化运维。
- Agent 开发框架 agentcube**: 参与开源项目初版建设, 负责 sandbox Python SDK 架构设计。实现 code-interpreter 等 Sandbox 的创建与管理能力, 降低 Agent 应用开发复杂度, 推动社区生态发展。
- NPU 虚拟化预研**: 主导用户态虚拟化技术预研, 完成 NPU-RTV 方案功能验证与落地方案设计。基于 Mind IE 框架部署优化主流 LLM 推理模型, 通过系统化性能测试为产品技术选型提供关键数据支撑。

实习经历

百度

2023/02 – 2023/06

BML, AI 平台部, AI 平台研发实习生

北京

- 模型算子组件**: 负责数据库连接、Shell 脚本等组件适配, 扩展 BML 可视化 AI 工作流的数据源与执行方式。
- 分支节点组件**: 设计并实现工作流条件分支组件, 通过解析 Json 条件表达式动态设置 Argo when 规则, 实现工作流条件路由。

专业技能

- 编程语言**: Go, Python
- 云原生**: Kubernetes(Device Plugin, Scheduler, CRD, Controller), Docker, Helm
- AI 基础设施**: GPU/NPU 虚拟化, Volcano, kthena
- 英语**: CET-4 570, CET-6 528, 可流畅阅读英文技术文档